

SPEECH EJECUTIVO BILINGÜE — CVM Analytics Case • CellMov Cross-Sell

Daniel Silva Barrera • Julio 2026 Duración objetivo: 15-18 min ($\approx$ 1.5-2 min por slide) + Q&A.

SLIDE 1 — Introducción / Portada

es Español

Buenos días. Gracias por el tiempo. Mi nombre es Daniel Silva y en los próximos quince minutos voy a mostrarles cómo pasar de una estrategia de oferta única —la misma para todos— a una personalización dirigida por Machine Learning, y qué vale eso exactamente en dinero.

Permítanme empezar por el final: sobre la misma base oficial de validación de cincuenta mil leads, un recomendador de ofertas basado en IA multiplica el margen de campaña por 4.7 veces frente a la estrategia actual de bajo costo. Ciento cinco mil dólares adicionales por cada ola de campaña, sin comprar un solo lead nuevo y sin cambiar el canal.

El resto de la presentación explica de dónde sale ese número, por qué es defendible y cómo lo escalamos. Recorreremos el perfil de la base, la lectura de los dos experimentos de campo, la elasticidad precio, la arquitectura del modelo, los resultados comparados y, finalmente, una propuesta de evolución hacia un ciclo agéntico de CVM.

GB English

Good morning, and thank you for your time. My name is Daniel Silva, and over the next fifteen minutes I'll show you how to move from a one-size-fits-all offer strategy to Machine Learning-driven personalization — and exactly what that is worth in dollars.

Let me start with the conclusion: on the same official fifty-thousand-lead validation base, an AI offer recommender multiplies campaign margin by 4.7 times versus today's fixed low-cost strategy. That's an additional one hundred and five thousand dollars per campaign wave — without buying a single new lead and without changing the channel.

The rest of this deck explains where that number comes from, why it holds up to scrutiny, and how we scale it. We'll walk through the lead base profile, the read-out from the two field experiments, price elasticity, the model architecture, the head-to-head results, and finally a proposal to evolve this into an agentic CVM loop.

SLIDE 2 — Executive Summary

es Español

Déjenme enmarcar esto en tres movimientos: situación, complicación y resolución.

Situación. CellMov lidera en móvil, pero es un número dos distante en banda ancha fija. El cross-sell mediante llamadas salientes es la palanca de crecimiento disponible hoy, y hay un hecho operativo que gobierna todo el caso: la primera oferta que el asesor pone sobre la mesa decide la llamada.

Complicación. Hoy esa decisión no es analítica. Cuando asignamos ofertas al azar, convertimos 0.9%. Cuando operaciones aplica la oferta fija de bajo costo, subimos a 2.3% — una mejora real—, pero pagamos un precio: el margen queda topado en 25 dólares por conversión, porque le estamos vendiendo el paquete más barato a absolutamente todo el mundo, incluido el cliente que habría pagado tres veces más.

Resolución. Un recomendador tipo *contextual bandit* asigna a cada cliente el bundle válido que maximiza el margen esperado: probabilidad de conversión multiplicada por el margen del bundle. Sobre la base oficial de test de cincuenta mil leads, eso da 5.7% de conversión y 133,848 dólares de margen.

Los cuatro indicadores de la derecha resumen el caso: la conversión recorre 0.9%, 2.3%, 5.7%. El margen por lead pasa de 57 centavos a 2.68 dólares. Eso son 4.67 veces el margen de la estrategia actual —más ciento cinco mil dólares— y 7.11 veces la línea base aleatoria.

Un punto de credibilidad antes de avanzar: las tres estrategias se evalúan sobre exactamente la misma base de validación. Es una comparación limpia, no un escenario optimista.

GB English

Let me frame this in three moves: situation, complication, resolution.

Situation. CellMov leads in mobile but is a distant number two in fixed broadband. Cross-sell through outbound calls is the growth lever available today, and one operational fact governs the entire case: the first offer the agent puts on the table decides the call.

Complication. Today that decision is not analytical. When we assign offers at random, we convert at 0.9%. When operations applies the fixed low-cost offer, we reach 2.3% — a genuine improvement — but we pay for it: margin is capped at twenty-five dollars per conversion, because we are selling the cheapest bundle to absolutely everyone, including the customer who would have paid three times more.

Resolution. A contextual-bandit recommender assigns each customer the valid bundle that maximizes expected margin: probability of conversion times bundle margin. On the

official fifty-thousand-lead test base, that delivers 5.7% conversion and 133,848 dollars in margin.

The four indicators on the right summarize the case: conversion travels from 0.9% to 2.3% to 5.7%. Margin per lead moves from 57 cents to 2.68 dollars. That is 4.67 times the margin of today's strategy — an extra one hundred and five thousand dollars — and 7.11 times the random baseline.

One credibility point before we move on: all three strategies are evaluated on exactly the same validation base. This is a clean comparison, not an optimistic scenario.

SLIDE 3 — Lead Base Profiling

es Español

Antes de modelar, hay que entender a quién le estamos llamando. Y el primer hallazgo es que la base de cien mil leads no es un mercado, son varios micro-mercados conviviendo.

Primero, la afluencia es escasa, no abundante. El segmento A es una minoría de la base; sin embargo —y el modelo lo confirmaría después con un coeficiente de +2.83 en log-odds— es el que concentra la mayor propensión a convertir. La restricción del negocio no es el volumen de leads, es la calidad. Eso ya sugiere que gastar el mismo esfuerzo comercial en todos es ineficiente.

Segundo, el tiempo en casa es el mejor proxy de necesidad de producto fijo. Los perfiles *home-centric* concentran el consumo de streaming —Netflix, Disney, YouTube—, y son los candidatos naturales para internet de alta velocidad, TV Premium y paquetes OTT. En contraste, los usuarios de alta movilidad están estructuralmente sub-indexados en necesidad de producto fijo: no es que rechacen el precio, es que no están en casa para usarlo.

Tercero, de ahí emergen tres personas comerciales: el *Affluent Home Streamer* —segmentos A y B, centrado en el hogar, alto consumo OTT—, al que le corresponden bundles premium; el *Value Commuter* —segmentos C y D, con rutina casa-trabajo—, al que le corresponden ofertas ligeras; y el *Mobile-First Nomad*, de alta movilidad, que es el encaje más difícil para producto fijo.

La conclusión estratégica es simple: si tres personas distintas requieren tres conversaciones distintas, una sola oferta fija necesariamente deja valor sobre la mesa.

GB English

Before modeling, we need to understand who we are calling. And the first finding is that the hundred-thousand-lead base is not one market — it is several micro-markets coexisting.

First, affluence is scarce, not abundant. Segment A is a minority of the base; yet — and the model later confirms this with a +2.83 log-odds coefficient — it carries the highest propensity to convert. The binding constraint in this business is not lead volume, it is lead quality. That alone suggests spending equal commercial effort on everyone is inefficient.

Second, time at home is the best proxy for fixed-product need. Home-centric profiles concentrate streaming consumption — Netflix, Disney, YouTube — and are the natural targets for high-speed internet, Premium TV and OTT bundles. High-mobility users, by contrast, structurally under-index on fixed-product need: it isn't that they reject the price, it's that they aren't home to use it.

Third, three commercial personas emerge: the Affluent Home Streamer — segments A and B, home-centric, heavy OTT — who maps to premium bundles; the Value Commuter — segments C and D, home-to-work routine — who maps to lean offers; and the Mobile-First Nomad, high mobility, the hardest fixed-product fit.

The strategic conclusion is simple: if three distinct personas require three distinct conversations, a single fixed offer necessarily leaves value on the table.

SLIDE 4 — Experiment Assessment

es Español

Ahora pasemos de la descripción a la evidencia causal. Tenemos dos experimentos de campo, cien mil leads, cincuenta mil por brazo.

El primer resultado es contundente y, honestamente, incómodo para el modelador: una oferta barata, simple y universalmente comprensible más que triplica la conversión aleatoria —de 0.73% a 2.50%—, llevando el margen de 13.4 mil a 31.4 mil dólares. Operaciones acertó. Pero ese es el punto: es un techo, no una estrategia. Funciona porque elimina fricción cognitiva, y al hacerlo deja la demanda premium completamente desatendida.

El segundo resultado invierte una intuición común: la relevancia le gana al precio. Los componentes premium convierten mejor que los baratos incluso a mayor precio. TV Premium convierte 0.78%, High Speed 0.76%, ambos por encima de Basic TV con 0.45%. No estamos ante un mercado que solo compra barato; estamos ante un mercado que compra lo que le sirve.

Tercero, y esto es accionable de inmediato: la línea de voz destruye llamadas. Convierte 0.21%, y en el modelo logit pesa -1.31 en log-odds con p menor a 0.001. Empaquetar voz "para agregar valor" está activamente saboteando la conversión. Esa es una decisión que se puede corregir mañana, sin modelo.

Y la inferencia que ata todo: los bundles ganadores del brazo aleatorio se separan en dos familias. Los *lean & cheap* —Low Speed solo, 6.3% de conversión— y los *rich & premium* —High Speed más Premium TV más Disney más WiFi, 3.9% de conversión y el mayor margen por cliente, 1.99 dólares. Dos familias de demanda coexisten en una misma base. Una oferta fija no puede servir a ambas. La personalización sí.

GB English

Let's move from description to causal evidence. We have two field experiments: one hundred thousand leads, fifty thousand per arm.

The first result is emphatic and, frankly, humbling for the modeler: a cheap, simple, universally understandable offer more than triples random conversion — from 0.73% to 2.50% — lifting margin from 13.4 thousand to 31.4 thousand dollars. Operations got this right. But that is precisely the point: it is a ceiling, not a strategy. It works by removing cognitive friction, and in doing so it leaves premium demand entirely unserved.

The second result overturns a common intuition: relevance beats price. Premium components out-convert cheap ones even at higher price points. Premium TV converts at 0.78%, High Speed at 0.76% — both above Basic TV at 0.45%. This is not a market that only buys cheap; it is a market that buys what is useful to it.

Third, and immediately actionable: the voice line is a conversion killer. It converts at 0.21%, and in the logit model it carries -1.31 log-odds, significant at p below 0.001. Bundling voice "for added value" is actively destroying calls. That is a decision you can fix tomorrow, with no model at all.

And the inference that ties it together: the winning bundles in the random arm split into two families. Lean and cheap — Low Speed alone at 6.3% conversion — and rich and premium — High Speed plus Premium TV plus Disney plus WiFi at 3.9% conversion and the highest margin per customer at 1.99 dollars. Two demand families coexist in one base. One fixed offer cannot serve both. Personalization can.

SLIDE 5 — Price Elasticity

es Español

La pregunta natural del negocio es: ¿entonces simplemente bajamos precios? La respuesta es no, y la elasticidad explica por qué.

Magnitud. Manteniendo el mix de producto constante, cada dólar adicional de precio multiplica los odds de conversión por 0.9437 —es decir, los reduce 5.6% por dólar—. El coeficiente es -0.058 log-odds por dólar, con p igual a 0.028. Es estadísticamente

significativo y consistente con la teoría de demanda estándar: la demanda tiene pendiente negativa, como esperábamos.

Confirmación de campo, con una advertencia honesta. Al pasar del mix aleatorio de 59.52 dólares promedio a la oferta de bajo costo de 37 dólares, la conversión sube 1.77 puntos porcentuales, 3.41 veces la línea base. Ahora bien, quiero ser explícito en algo: esa oferta de bajo costo no solo baja el precio, también elimina add-ons. Parte de ese lift es simplificación del mix, no efecto puro de precio. Reportarlo como elasticidad pura sería sobrevender el hallazgo.

Heterogeneidad, y aquí está la decisión estratégica. Manteniendo el precio constante, High Speed aporta +0.82 log-odds con p igual a 0.023, y Premium TV aporta +1.13 con p igual a 0.07. Es decir: las características premium tienen utilidad positiva que compensa el precio, para el cliente correcto. La elasticidad depende del perfil.

La implicación para el C-Level es directa: un descuento generalizado regala margen en el segmento que habría pagado. Los recortes de precio solo rinden en los segmentos de valor. Eso es exactamente el argumento a favor de bundles personalizados y en contra de descuentos transversales.

GB English

The natural business question is: so should we simply cut prices? The answer is no — and elasticity explains why.

Magnitude. Holding product mix fixed, each additional dollar of price multiplies conversion odds by 0.9437 — a 5.6% reduction per dollar. The coefficient is -0.058 log-odds per dollar, with p equal to 0.028. It is statistically significant and consistent with standard demand theory: demand slopes down, as expected.

Field confirmation, with an honest caveat. Moving from the random mix at 59.52 dollars average to the low-cost offer at 37 dollars lifts conversion by 1.77 percentage points, 3.41 times baseline. But I want to be explicit about something: that low-cost offer doesn't only lower price, it also strips add-ons. Part of that lift is mix simplification, not pure price effect. Reporting it as pure elasticity would be overselling the finding.

Heterogeneity — and here is the strategic decision. Holding price constant, High Speed adds +0.82 log-odds at p equal to 0.023, and Premium TV adds +1.13 at p equal to 0.07. Premium features carry positive utility that offsets price, for the right customer. Elasticity is profile-dependent.

The C-level implication is direct: a blanket discount gives away margin in the very segment that would have paid. Price cuts only pay off in value segments. That is precisely the argument for personalized bundles and against across-the-board discounting.

SLIDE 6 — Model Architecture & Parameter Justification

es Español

Con esa evidencia, la arquitectura se vuelve casi obligada. Elegimos un *contextual bandit*, y quiero recorrerlo en cinco piezas porque cada parámetro responde a una razón de negocio, no a una preferencia técnica.

Contexto: tres variables categóricas codificadas one-hot y nueve variables numéricas de uso, estandarizadas. Es el cliente tal como lo conocemos antes de marcar.

Espacio de acción: noventa y seis bundles válidos por construcción —dos opciones de internet, por tres de TV, por dieciséis combinaciones de add-ons—. Este punto es importante para riesgo y para operaciones: las ofertas inválidas no son penalizadas, son directamente imposibles de generar.

Política: epsilon-greedy. Con probabilidad épsilon exploramos un bundle válido al azar; el resto del tiempo explotamos la mejor acción del modelo.

Modelo de recompensa: una regresión logística que estima la probabilidad de conversión dado cliente y oferta, y elegimos el argmax de probabilidad por margen.

Ciclo de aprendizaje: diez olas quincenales de cincuenta mil leads, reentrenando sobre todo el histórico acumulado de contexto, acción y recompensa.

Sobre las decisiones de diseño, brevemente: el épsilon baja linealmente de 1.0 a 0.05 a lo largo de las diez olas —exploración total cuando no existe modelo, explotación casi total cuando ya hay confianza—, y ese calendario espeja el ciclo real de campañas quincenales. Elegimos regresión logística en lugar de gradient boosting o redes neuronales por tres razones: coeficientes interpretables que marketing puede leer y desafiar, velocidad para puntuar 4.8 millones de pares cliente-oferta, y porque un modelo plenamente entendido y auditable vale más aquí que uno marginalmente más preciso. El *class_weight* balanceado evita que el modelo colapse a "nunca convierte" cuando la tasa base está por debajo del 3%. Y el objetivo es argmax de probabilidad por margen, no de conversión: optimizamos lo que le importa al CMO.

La prueba de que el ciclo aprende está en la curva: ola uno, 0.95% de conversión y 18 mil dólares de margen. Ola diez, 5.40% y 128.9 mil dólares. La caída en la ola ocho es varianza de muestreo con épsilon todavía en 0.26 —la menciono explícitamente porque una curva perfectamente monótona sería la señal de alerta, no lo contrario—.

GB English

Given that evidence, the architecture becomes almost self-selecting. We chose a contextual bandit, and I want to walk through it in five pieces, because every parameter answers a business reason, not a technical preference.

Context: three categorical features, one-hot encoded, and nine numeric usage features, standardized. This is the customer as we know them before we dial.

Action space: ninety-six valid bundles by construction — two internet options, times three TV options, times sixteen add-on combinations. This matters for risk and for operations: invalid offers are not penalized, they are structurally impossible to generate.

Policy: epsilon-greedy. With probability epsilon we explore a random valid bundle; otherwise we exploit the model's best action.

Reward model: a logistic regression estimating probability of conversion given customer and offer, and we take the argmax of probability times margin.

Learning loop: ten biweekly waves of fifty thousand leads, retraining on the full accumulated history of context, action and reward.

On the design choices, briefly: epsilon decays linearly from 1.0 to 0.05 across the ten waves — full exploration at cold start when no model exists, near-full exploitation once confident — and that schedule mirrors the real biweekly campaign calendar. We chose logistic regression over gradient boosting or neural networks for three reasons: interpretable coefficients marketing can read and challenge, the speed to score 4.8 million customer-offer pairs, and because a fully understood, auditable model is worth more here than a marginally more accurate one. Balanced class weighting prevents the model from collapsing to "never converts" when the base rate is under 3%. And the objective is argmax of probability times margin, not conversion: we optimize what the CMO actually cares about.

Proof the loop learns is in the curve: wave one, 0.95% conversion and 18 thousand dollars of margin. Wave ten, 5.40% and 128.9 thousand dollars. The dip at wave eight is sampling variance with epsilon still at 0.26 — and I flag it deliberately, because a perfectly monotonic curve would be the red flag, not this.

SLIDE 7 — Results: Three Strategies Compared

es Español

Estos son los resultados sobre el conjunto de test oficial: cincuenta mil leads, la misma base idéntica para las tres estrategias.

La oferta aleatoria convierte 470 leads, 0.9%, con 18,829 dólares de margen. La oferta fija de bajo costo casi triplica ese volumen —1,143 conversiones, 2.3%— pero solo llega a 28,644 dólares, porque el margen por conversión cae a 25 dólares. El bandit contextual convierte 2,863 leads, 5.7%, y genera 133,848 dólares, con 46.75 dólares de margen por conversión.

Miren la columna de margen por lead, porque es la métrica que se puede llevar directo a presupuesto: de 38 centavos, a 57 centavos, a 2.68 dólares. En términos de lift: 105,205 dólares adicionales frente a la estrategia actual, un 4.67x; y 115,020 frente a la aleatoria, 7.11x.

Ahora, la prueba de que esto es personalización real y no un truco. La política usa activamente 6 de los 96 bundles válidos. El 77.7% de los leads recibe High Speed con WiFi; un 9.3% añade Premium TV; un 6.9% añade Premium TV y Disney; el resto se distribuye en variantes. Y hay tres cosas que el modelo nunca recomienda: Low Speed, Basic TV y voz por separado —exactamente lo opuesto a la estrategia operativa de hoy—. Además siempre adjunta el add-on de WiFi de 4 dólares, porque eleva el valor percibido más de lo que castiga vía precio.

Anticipo la objeción legítima: si el 78% recibe el mismo bundle, ¿es realmente personalización? Sí, y por una razón estadística sólida: el argmax de margen esperado se concentra legítimamente cuando un bundle domina la mayor parte del espacio de clientes. La personalización no está en la base del bundle, está en **a quién** se le añade Premium TV o Disney. Ahí es donde se captura el margen incremental.

Y por qué gana: los principales drivers del modelo son Segmento A con +2.83 log-odds, movilidad *home-centric* con +2.14, línea de voz con -2.61, movilidad casa-trabajo-tercer-sitio con -2.17 y dispositivo iPhone gama media con -1.57. Noten lo que ocurrió: el modelo redescubrió y cuantificó de forma independiente exactamente la intuición de negocio que vimos en el perfilamiento y en los experimentos. Cuando la evidencia descriptiva, la experimental y la del modelo convergen, la confianza para actuar es mucho mayor.

GB English

These are the results on the official test set: fifty thousand leads, the identical base for all three strategies.

The random offer converts 470 leads, 0.9%, at 18,829 dollars of margin. The fixed low-cost offer nearly triples that volume — 1,143 conversions, 2.3% — but only reaches 28,644 dollars, because margin per conversion collapses to 25 dollars. The contextual bandit converts 2,863 leads, 5.7%, and generates 133,848 dollars, at 46.75 dollars margin per conversion.

Look at the margin-per-lead column, because that is the metric you can take straight into a budget: 38 cents, 57 cents, 2.68 dollars. In lift terms: 105,205 dollars incremental versus today's strategy, a 4.67x; and 115,020 versus random, 7.11x.

Now, the proof this is genuine personalization and not a trick. The policy actively uses 6 of the 96 valid bundles. 77.7% of leads receive High Speed with WiFi; 9.3% add Premium TV; 6.9% add Premium TV and Disney; the remainder spread across variants. And there are three things the model never recommends: Low Speed, Basic TV, and standalone voice —

the exact opposite of today's operational strategy. It also always attaches the four-dollar WiFi add-on, because it raises perceived value more than it costs in price sensitivity.

Let me pre-empt the fair objection: if 78% get the same bundle, is this really personalization? Yes — and for a sound statistical reason. The argmax of expected margin legitimately concentrates when one bundle dominates most of the customer space. The personalization is not in the base bundle; it is in **who** gets Premium TV or Disney attached. That is where the incremental margin is captured.

And why it wins: the top model drivers are Segment A at +2.83 log-odds, home-centric mobility at +2.14, voice line attached at −2.61, home-work-third-site mobility at −2.17, and mid-end iPhone device at −1.57. Note what happened here: the model independently rediscovered and quantified exactly the business intuition we saw in the profiling and the experiments. When descriptive, experimental and model evidence converge, confidence to act is materially higher.

SLIDE 8 — Agentic AI Use-Case Proposal

es Español

Hasta aquí tenemos un modelo que funciona. La pregunta ejecutiva es cómo lo convertimos en una capacidad permanente. La propuesta es escalar el recomendador hacia un ciclo agéntico de CVM que componga el lift de ciento cinco mil dólares por ola y, en paralelo, reduzca el tiempo de ciclo de campaña de semanas a días.

Quiero ser muy explícito en un punto antes de describir la arquitectura: este diseño conceptual y lógico es completamente agnóstico a la tecnología. Lo que ven en pantalla son capas y responsabilidades —datos, núcleo de MLOps, capa de agentes, guardrails y activación—, no productos. Este mismo diseño se implementa igual de bien sobre AWS, sobre Azure, sobre Google Cloud o sobre un stack on-premise. La decisión de plataforma es una decisión de arquitectura empresarial y de contratos existentes, no una restricción del modelo. Eso protege la inversión: si CellMov cambia de proveedor cloud, la lógica de negocio sobrevive.

Dicho eso, para demostrar que esto es viable en un entorno empresarial real y no un diagrama de consultoría, permítanme mapearlo sobre servicios nativos de AWS.

Capa de datos. El feature store de uso y CDR, el CRM y los márgenes de facturación aterrizan en **Amazon S3** como data lake, con ingesta en tiempo real vía **Amazon Kinesis Data Streams** para los eventos de consumo. El **SageMaker Feature Store** garantiza que las features usadas en entrenamiento sean exactamente las mismas que se sirven en inferencia —eliminando el *training-serving skew*, que es la causa número uno de que estos modelos se degraden en producción—.

Núcleo de MLOps. El pipeline de features y el reentrenamiento corren en **Amazon SageMaker Pipelines**; los modelos se versionan en el **SageMaker Model Registry**; y el *serving* campeón-retador se expone mediante **SageMaker Endpoints** con variantes de producción, que permiten dividir tráfico entre modelo actual y candidato sin desplegar infraestructura nueva.

Capa de agentes. Los cuatro agentes se implementan como funciones **AWS Lambda** orquestadas por **AWS Step Functions** y disparadas por **Amazon EventBridge**. El agente de decisión de oferta ejecuta la política del bandit por lead en tiempo real y escala los casos de baja confianza a exploración; su estado, el histórico de asignaciones y el presupuesto de ϵ viven en **Amazon DynamoDB**, que da latencia de milisegundos —requisito no negociable cuando el asesor tiene al cliente en línea—. El agente de experimentación administra el presupuesto de ϵ y el diseño de holdout, garantizando que cada ola produzca datos de aprendizaje no sesgados. El agente de insight y narrativa, apoyado en **Amazon Bedrock**, traduce los desplazamientos de coeficientes en briefs semanales legibles por el CMO. Y el agente de monitoreo y drift usa **SageMaker Model Monitor** con alarmas en **Amazon CloudWatch** para vigilar la calibración y disparar reentrenamiento o rollback automático.

Guardrails. Y esto es tan importante como el modelo: las reglas de validez de las 96 acciones, los pisos de precio, la política de contacto y la aprobación humana para ofertas nuevas se implementan como capa de validación previa a la ejecución, con **AWS IAM** y **Amazon Bedrock Guardrails** delimitando lo que cada agente puede y no puede hacer. Ningún agente lanza una oferta fuera del espacio autorizado.

Activación. La oferta llega al asesor a través del CTI del contact center —en AWS, **Amazon Connect** integrado con el marcador predictivo y el campaign manager—.

Cuatro procesos se transforman: el scoring y asignación de oferta pasa de reglas promocionales manuales mensuales a una política aprendida en tiempo real; el diseño experimental pasa de tests ad-hoc a gestión automatizada de ϵ y holdout; el guion de primera oferta pasa de genérico a personalizado —y recuerden que el caso demostró que la primera oferta decide la llamada—; y el monitoreo pasa de revisiones manuales a un ciclo continuo disparado por drift.

Cómo medimos el valor incremental, que es la pregunta que todo comité debe hacer: mantenemos un holdout aleatorizado permanente, aproximadamente el 5% de los leads bajo la regla actual de bajo costo. El margen incremental por ola es simplemente el margen del sistema agéntico menos el margen del holdout escalado. Como KPIs secundarios: tiempo de ciclo de diseño a lanzamiento, porcentaje de ofertas auto-aprobadas dentro de guardrails, y error de calibración del modelo. La línea base está anclada en el lift medido de ciento cinco mil dólares por ola de cincuenta mil leads.

GB English

So far we have a model that works. The executive question is how we turn it into a permanent capability. The proposal is to scale the recommender into an agentic CVM loop that compounds the one-hundred-and-five-thousand-dollar lift per wave while cutting campaign cycle time from weeks to days.

I want to be very explicit on one point before describing the architecture: this conceptual and logical design is entirely technology-agnostic. What you see on screen are layers and responsibilities — data, MLOps core, agent layer, guardrails and activation — not products. This same design implements equally well on AWS, on Azure, on Google Cloud, or on an on-premise stack. Platform choice is an enterprise-architecture and existing-contracts decision, not a constraint of the model. That protects the investment: if CellMov changes cloud provider, the business logic survives.

That said, to demonstrate this is viable in a real enterprise environment and not a consulting diagram, let me map it onto native AWS services.

Data layer. The usage and CDR feature store, CRM, and billing margins land in **Amazon S3** as the data lake, with real-time ingestion via **Amazon Kinesis Data Streams** for consumption events. **SageMaker Feature Store** guarantees that the features used in training are exactly the features served at inference — eliminating training-serving skew, which is the number-one reason these models degrade in production.

MLOps core. The feature pipeline and retraining run on **Amazon SageMaker Pipelines**; models are versioned in the **SageMaker Model Registry**; and champion/challenger serving is exposed through **SageMaker Endpoints** with production variants, which let us split traffic between the incumbent and the candidate model without standing up new infrastructure.

Agent layer. The four agents are implemented as **AWS Lambda** functions, orchestrated by **AWS Step Functions** and triggered by **Amazon EventBridge**. The Offer Decision agent runs the bandit policy per lead in real time and escalates low-confidence cases to exploration; its state, assignment history and epsilon budget live in **Amazon DynamoDB**, which gives millisecond latency — a non-negotiable requirement when the agent has the customer on the line. The Experimentation agent owns the epsilon budget and holdout design, ensuring every wave produces unbiased learning data. The Insight and Narrative agent, powered by **Amazon Bedrock**, turns coefficient shifts into weekly CMO-readable briefs. And the Monitoring and Drift agent uses **SageMaker Model Monitor** with **Amazon CloudWatch** alarms to watch calibration and trigger retraining or automatic rollback.

Guardrails. And this matters as much as the model: the 96-action validity rules, pricing floors, contact policy and human approval for new offers are implemented as a pre-execution validation layer, with **AWS IAM** and **Amazon Bedrock Guardrails** bounding

what each agent can and cannot do. No agent ever fires an offer outside the authorized space.

Activation. The offer reaches the agent through the contact-center CTI — on AWS, **Amazon Connect** integrated with the predictive dialer and campaign manager.

Four processes are transformed: lead scoring and offer assignment moves from monthly manual promo rules to a real-time learned policy; experiment design moves from ad-hoc tests to automated epsilon and holdout management; the first-pitch call script moves from generic to personalized — and recall the case showed the first offer decides the call; and monitoring moves from manual reviews to a continuous drift-triggered loop.

How we measure incremental value, which is the question every steering committee should ask: we maintain a permanent randomized holdout, roughly 5% of leads on the current low-cost rule. Incremental margin per wave is simply the margin of the agentic system minus the scaled margin of the holdout. Secondary KPIs: cycle time from design to launch, percentage of offers auto-approved within guardrails, and model calibration error. The baseline is anchored on the measured plus-one-hundred-and-five-thousand-dollar lift per fifty-thousand-lead wave.

SLIDE 9 — How AI Was Used to Develop This Case

es Español

Cierro con transparencia sobre el método, porque creo que en 2026 esta es una conversación que merece ser explícita y no una nota al pie.

La IA actuó como *pair-programmer* y socio de pensamiento bajo dirección humana. Cada línea de código, cada parámetro y cada insight fue revisado y es de mi propiedad intelectual y responsabilidad.

En exploración, la IA redactó el boilerplate de matplotlib y seaborn para los gráficos de distribución y análisis multivariado. Mi rol fue definir qué pregunta de negocio debía responder cada gráfico y descartar los que no aportaban insight —que fueron varios—.

En modelado, la IA propuso arquitecturas candidatas: un modelo multiclase, modelos por oferta, y el bandit contextual; y redactó el código de implementación. La decisión fue mía: elegí el bandit por su encaje con el diseño secuencial de diez olas y por el criterio de "plenamente entendido por encima de complejo". Desafié cada parámetro: el calendario de epsilon, el balanceo de clases, las restricciones del espacio de acción.

En interpretación y storytelling, la IA sirvió como contraparte crítica: puso a prueba mis interpretaciones —log-odds contra puntos porcentuales, el confundido entre mix y precio que mencioné en el slide de elasticidad— y ayudó a estructurar este deck bajo el Principio

de la Pirámide. Los insights finales, la verificación de cada número contra las salidas ejecutadas del notebook, el storytelling y el deck final son míos.

Sobre el stack: VS Code con Opus 4.8 para redactar código, con el autocompletado de celda bloqueado dentro de CLAUDE.md y todos los prompts de generación de código registrados. Mejora de prompts con un Gem en Gemini. Análisis de resultados con Fable, en modo asistido, no automatizado.

La razón por la que esto importa a nivel ejecutivo: la trazabilidad del proceso es lo que permite auditar el resultado. Un modelo que nadie puede explicar no es un activo, es un riesgo.

Con eso cierro. Quedo atento a sus preguntas.

GB English

Let me close with transparency on method, because I believe in 2026 this deserves to be an explicit conversation, not a footnote.

AI acted as a pair-programmer and thought partner under human direction. Every line of code, every parameter and every insight was reviewed and is mine to own and defend.

In exploration, AI drafted the matplotlib and seaborn boilerplate for the distribution and multivariate charts. My role was defining which business question each chart had to answer, and discarding the ones that carried no insight — of which there were several.

In modeling, AI proposed candidate architectures: a multiclass model, per-offer models, and the contextual bandit; and drafted implementation code. The decision was mine: I selected the bandit for its fit with the sequential ten-wave design and for the "fully understood over complex" criterion. I challenged every parameter — the epsilon schedule, class weighting, action-space constraints.

In interpretation and storytelling, AI served as a critical counterpart: it stress-tested my interpretations — log-odds versus percentage points, the mix-versus-price confound I flagged on the elasticity slide — and helped structure this deck under the Pyramid Principle. The final insights, the verification of every number against executed notebook outputs, the storytelling and the final deck are mine.

On the stack: VS Code with Opus 4.8 for drafting code, with cell autocomplete blocked inside CLAUDE.md and all code-generation prompts logged. Prompt improvement via a Gem in Gemini. Result analysis with Fable — assisted, not automated.

Why this matters at executive level: traceability of process is what makes the outcome auditable. A model nobody can explain is not an asset — it is a liability.

With that, I'll close. I'm happy to take your questions.

ANEXO — Preguntas probables del comité / Likely Q&A

Pregunta	Respuesta corta
¿El 78% de un solo bundle no es "no personalización"?	El argmax se concentra cuando un bundle domina el espacio; la personalización está en los add-ons diferenciales y en el 22% restante.
¿Cómo sabemos que el $4.67\times$ no es overfitting?	Base de validación oficial, idéntica para las tres estrategias, no usada en entrenamiento.
¿Cuánto tarda la fase de aprendizaje?	10 olas quincenales; el lift material aparece a partir de la ola 9 ($\epsilon \leq 0.16$). El holdout permanente protege el downside.
¿Por qué no un modelo más potente (GBM/NN)?	Trade-off deliberado: interpretabilidad y velocidad de scoring (4.8M pares) sobre ganancia marginal de precisión. Es la fase 1, no el techo.
¿Qué pasa si eliminamos voz de los bundles mañana?	Es la acción de mayor ROI sin modelo: -1.31 log-odds, $p < 0.001$.